ANÁLISIS EXPLORATORIO DE DATOS Y SELECCIÓN DEL MODELO DE LENGUAJE

Documento complementario — Sistema de preguntas y respuestas sobre el contenido de un video mediante LLM

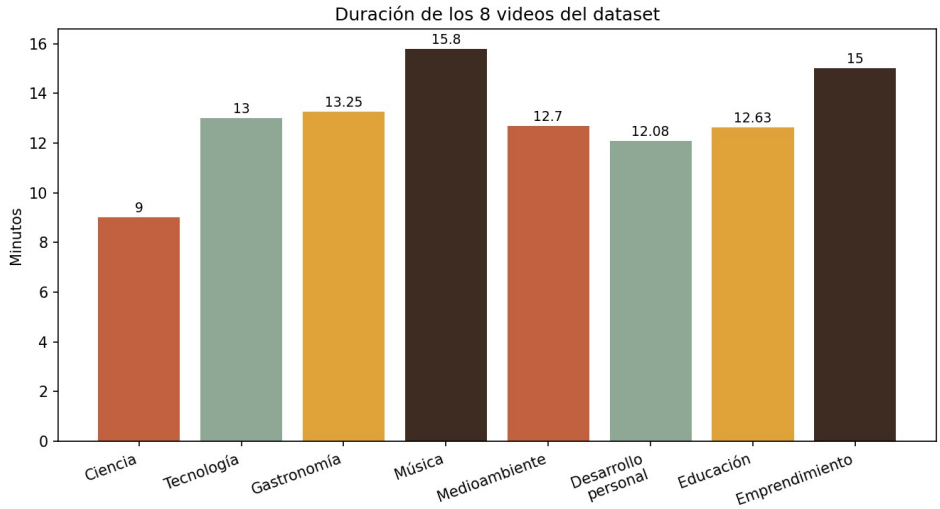
1. Alcance de este análisis

Un análisis exploratorio de datos (EDA) tradicional se realiza sobre el texto ya transcrito: distribución de palabras, muletillas, errores de transcripción, etc. En esta etapa del proyecto los 8 videos del dataset aún no han sido transcritos, por lo que este documento presenta dos cosas: (1) un EDA de los metadatos actualmente disponibles del dataset (duración, tema, fuente) y una estimación fundamentada del tamaño del corpus, y (2) la comparación crítica de todas las opciones evaluadas para los componentes de inteligencia artificial del sistema (modelo de lenguaje, transcripción automática, embeddings y base vectorial), con la recomendación final y sus fuentes.

2. EDA de metadatos del dataset

El dataset está compuesto por 8 videos reales, en español, de temáticas distintas entre sí, todos por debajo del límite de 25 minutos establecido para el proyecto.

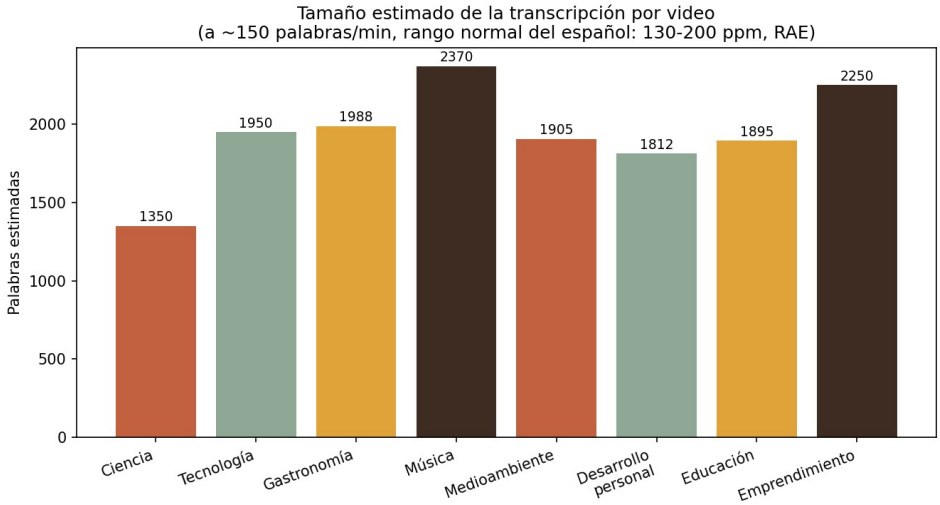
#	Título del video	Tema	Duración	Fuente
1	Las matemáticas son para siempre — Eduardo Sáenz de Cabezón (TED)	Ciencia / matemáticas	9:00	youtube.com/watch?v=lmFUp4K8fFc
2	El futuro de la privacidad — Sebastián Bortnik (TEDxSanIsidro)	Tecnología / privacidad	13:00	youtube.com/watch?v=TjsCyfkKPk0
3	¿Puede la cocina cambiar el mundo? — Gastón Acurio (TED)	Gastronomía	13:15	ted.com/talks/gaston_acurio…
4	¿Por qué nos emociona la música? — Paolo Bortolameolli (TED)	Música	15:48	ted.com/talks/paolo_bortolameolli…
5	Por qué necesitamos proteger el alta mar — Enric Sala (TED)	Medioambiente	12:42	ted.com/talks/enric_sala…
6	El valor de nuestra diversidad interna — Rebeca Hwang (TED)	Desarrollo personal	12:05	ted.com/talks/rebeca_hwang…
7	La selección latinoamericana de cerebros — Juan Enriquez (TED)	Educación / tecnología	12:38	ted.com/talks/juan_enriquez…
8	Una nueva manera de hablar del fracaso en los negocios — Leticia Gasca (TED)	Emprendimiento	15:00	ted.com/talks/leticia_gasca…



Duración total del dataset: ≈ 103 minutos. Rango: 9 a 15.8 minutos. No se observan valores atípicos: los 8 videos están dentro de un rango homogéneo.

3. Estimación del tamaño del corpus

Como aún no existen las transcripciones, el tamaño del corpus se estima a partir de la velocidad de habla documentada para el español. El Libro de estilo de la lengua española de la RAE sitúa la velocidad normal de habla entre 130 y 200 palabras por minuto, y un análisis específico de charlas TED encontró un promedio de 163 palabras por minuto. Tomando 150 palabras por minuto como punto medio conservador, se estima lo siguiente:



Total estimado del corpus: ≈ 15.500 palabras. Esta cifra debe compararse contra el conteo real una vez se transcriban los videos; esa comparación (estimado vs. real) es un hallazgo válido para reportar en el EDA definitivo.

4. Confiabilidad esperada de la transcripción

Benchmarks recientes (2026) de Whisper Large-v3 reportan un Word Error Rate (WER) de aproximadamente 5% en español, frente a 8–12% en inglés en condiciones reales de audio. Esto significa que, en promedio, alrededor de 1 de cada 20 palabras transcritas podría contener un error, lo cual justifica la etapa de preprocesamiento y limpieza definida en la metodología del proyecto.

5. Comparación de todas las opciones evaluadas

5.1 Modelo de lenguaje (LLM)

Modelo	Tipo	Desempeño en español	Costo	Decisión
Llama 3.2 3B Instruct	Abierto, local	Modelo ligero optimizado para diálogo multilingüe; español es uno de los 8 idiomas oficialmente soportados por Meta.	Gratis, ≈ 4 GB RAM	Recomendado (bajo consumo)
Qwen2.5 3B Instruct	Abierto, local	Alternativa de tamaño similar; buen desempeño multilingüe general.	Gratis, ≈ 4 GB RAM	Alternativa (bajo consumo)
Qwen3 (7B)	Abierto, local	Líder en benchmarks multilingües recientes; en español queda por delante de modelos de tamaño similar.	Gratis, ≈ 8 GB RAM	Alternativa (mayor consumo)
Llama 3.3 (8B)	Abierto, local	Muy competitivo en español; el más documentado y con mayor soporte de comunidad.	Gratis, ≈ 8 GB RAM	Alternativa (mayor consumo)
GPT-4o mini (referencia)	Cerrado, API	Muy buen desempeño en español, pero requiere pago por uso y depende de un servicio externo.	De pago	Descartado: rompe el requisito de sistema local y gratuito

5.1.1 Especificaciones oficiales — Llama 3.2 3B Instruct

Ficha técnica del modelo recomendado, según la tarjeta de modelo publicada oficialmente por Meta en Hugging Face, complementada con datos de despliegue reportados por la comunidad (Ollama).

Especificación	Valor
Desarrollador	Meta AI
Arquitectura	Transformer autorregresivo (decoder-only), ajustado con SFT (fine-tuning supervisado) y RLHF
Parámetros	3,000 millones (3B)
Longitud de contexto	128.000 tokens
Datos de entrenamiento	Hasta 9 billones de tokens de fuentes públicas
Idiomas oficialmente soportados	Inglés, alemán, francés, italiano, portugués, hindi, español y tailandés
Licencia	Llama 3.2 Community License (Meta) — uso comercial y de investigación permitido, requiere aceptar los términos
Fecha de lanzamiento	25 de septiembre de 2024
Descarga cuantizada (Q4_K_M, vía Ollama)	≈ 2.5 GB en disco
RAM recomendada para ejecución local	≈ 4 GB
VRAM recomendada (si se usa GPU)	6 GB o más (opcional; el modelo corre en CPU sin GPU)

Especificación	Valor
Velocidad aproximada en CPU	≈ 45 tokens/segundo (equipo de gama media)
Comando de instalación	ollama pull llama3.2:3b

Nota: Meta no especifica en su tarjeta de modelo un requisito mínimo oficial de RAM/VRAM, ya que esto depende de la herramienta de despliegue usada. Los valores de RAM, velocidad y comando de instalación provienen de benchmarks de la comunidad (Ollama) sobre la versión cuantizada Q4_K_M del modelo.

5.2 Transcripción automática (ASR)

Herramienta	Precisión (WER)	Costo / despliegue	Decisión
Whisper large-v3 (OpenAI, open source)	≈ 5% WER en español (benchmarks 2026)	Gratis, corre localmente, MIT license	Recomendado
GPT-4o-transcribe (OpenAI, API)	WER algo menor que Whisper según OpenAI	De pago, requiere API externa	Descartado: no es local/gratuito
Amazon Transcribe	Competitivo en inglés; variable en español	De pago por minuto procesado	Descartado: mismo motivo

5.3 Embeddings (representación semántica)

Modelo	Características	Decisión
sentence-transformers/all-MiniLM-L6-v2	Muy liviano, corre en CPU sin problema; soporte multilingüe limitado	Opción base / prueba rápida
intfloat/multilingual-e5-base	Mejor soporte específico para español y otros idiomas; algo más pesado	Recomendado para este proyecto

5.4 Base de datos vectorial

Herramienta	Características	Decisión
ChromaDB	Local, gratuito, fácil de integrar en Python, sin necesidad de servidor externo	Recomendado
FAISS (Meta)	Muy rápido y liviano, pero requiere más código propio para persistencia	Alternativa técnica
Pinecone	Rápido y con buena documentación, pero es un servicio en la nube con planes de pago	Descartado: no es local/gratuito

6. Recomendación final

Con base en la comparación anterior, la configuración recomendada para el sistema es:

- Modelo de lenguaje (LLM): Llama 3.2 3B Instruct, priorizando bajo consumo de máquina; Qwen2.5 3B Instruct como alternativa de tamaño similar.

- Transcripción automática: Whisper large-v3, ejecutado localmente.
- Embeddings: intfloat/multilingual-e5-base, por su mejor soporte para español.
- Base de datos vectorial: ChromaDB, por su facilidad de integración local sin costos de nube.

Esta combinación cumple con el requisito central del proyecto: un sistema completamente gratuito, ejecutable localmente y replicable por cualquier persona, sin depender de servicios de pago.

7. Fuentes

- RAE — Libro de estilo de la lengua española, "La velocidad de habla": rae.es/libro-estilo-lengua-espanola/la-velocidad-de-habla
- Análisis de velocidad de habla en 9 charlas TED (promedio 163 ppm): respuestasrapidas.com.mx/cuantas-palabras-por-minuto-en-una-presentacion
- VexaScribe — Benchmark de WER de Whisper por idioma (2026): vexascribe.com/how-accurate-is-whisper
- PromptQuorum — "Mejores LLM locales multilingües 2026: Qwen3 vs Mistral": promptquorum.com/es/local-llms/multilingual-local-llms
- Meta AI — Tarjeta de modelo oficial, Llama 3.2 3B Instruct (Hugging Face): huggingface.co/meta-llama/Llama-3.2-3B-Instruct
- PromptQuorum — "Mejores LLM locales para principiantes 2026" (RAM, velocidad y comando de Ollama para Llama 3.2 3B): promptquorum.com/es/local-llms/best-beginner-local-llm-models